GraphRAG & n8n Setup - Cheat Sheet

Überblick

Dieses Cheat Sheet zeigt, wie du KI-Agenten mit GraphRAG und n8n zehnmal intelligenter machst. GraphRAG löst die Hauptprobleme traditioneller RAG-Systeme: Kontextverlust, fehlende Beziehungsverständnis und schlechte Antworten bei komplexen Fragen.

Was ist GraphRAG?

Wissensgraph Grundlagen

- Knoten/Entitäten: Personen, Kurse, Unternehmen (dargestellt als Kreise)
- Beziehungen: Verbindungen wie "arbeitet bei", "lebt in", "unterrichtet"
- Eigenschaften: Zusätzliche Infos wie "Computerscience-Kurs", "englischsprachig"

GraphRAG vs. Traditionelles RAG

Traditionelles RAG:

- Sucht isolierte Textschnipsel
- Verliert Kontext zwischen Informationen
- Versteht keine Beziehungen

GraphRAG:

- Nutzt Wissensgraphen für Zusammenhänge
- Kombiniert Vektorspeicher mit Graph-Datenbank
- Liefert kontextgenaue, fundierte Antworten

LightRAG vs. Microsoft GraphRAG

Microsoft GraphRAG:

- Sehr leistungsfähig bei globalen Fragen
- Teuer, langsam, schwer zu aktualisieren

LightRAG:

- Schlankere Alternative
- Dual-Level Retrieval (lokal + global)
- Günstiger, schneller, einfacher
- Open-Source

LightRAG Cloud-Setup

Voraussetzungen

- Render.com Account
- OpenAI API Key

Render.com Deployment

1. Neues Projekt erstellen

- o Gehe zu Render.com
- o Klicke auf "New" → "Web Service"
- o Wähle "Deploy an existing image"

2. Docker Image konfigurieren

- o Image URL: ghcr.io/hkuds/lightrag:latest
- o Name: Wähle einen Namen für deinen Service
- o Region: Wähle die nächstgelegene Region
- o Branch: main (Standard)

3. Instanztyp wählen

- o Plan: Starter (\$7/Monat) ausreichend für die meisten Anwendungen
- o Auto-Deploy: Aktiviert lassen

4. Persistente Speicherung

- o Gehe zu "Advanced"
- Klicke "Add Disk"
- o Name: lightrag-data
- o Mount Path: /var/data
- o Size: 1 GB (kann später erweitert werden)

5. Deploy starten

- o Klicke "Deploy"
- Warte auf Deployment-Abschluss

Umgebungsvariablen Setup

Wichtig: Alle Umgebungsvariablen müssen vor dem ersten Deployment gesetzt werden.

1. Basis-Authentifizierung

AUTH_ACCOUNTS

- Wert: nutzer123:passwort123
- Beschreibung: Login-Daten für LightRAG-Interface
- Format: Benutzername: Passwort
- Beispiel: admin: meinpasswort2024

LIGHTRAG API KEY

- Wert: apikey123
- Beschreibung: API-Schlüssel für n8n-Integration
- Beispiel: lightrag key 2024 secure
- Merke dir diesen Key du brauchst ihn später für n8n!

2. OpenAI & Embedding-Konfiguration

Füge diese Variablen über "Add Environment Variable" hinzu:

Embedding-Konfiguration:

```
EMBEDDING_BINDING=openai

EMBEDDING_MODEL=text-embedding-3-small

EMBEDDING_DIM=1536

EMBEDDING_BINDING_HOST=https://api.openai.com/v1

EMBEDDING_BINDING_API KEY=your openai api key
```

LLM-Konfiguration:

```
LLM_BINDING=openai
LLM_MODEL=gpt-4.1-nano
LLM_BINDING_HOST=https://api.openai.com/v1
LLM_BINDING_API KEY=your openai api key
```

Performance-Einstellungen:

```
MAX_ASYNC=6
MAX_PARALLEL_INSERT=3
EMBEDDING_FUNC_MAX_ASYNC=18
EMBEDDING_BATCH_NUM=100
```

3. Schritt-für-Schritt Anleitung

1. OpenAI API Key besorgen

- o Gehe zu platform.openai.com
- o Erstelle API Key
- o Ersetze your openai api key mit deinem echten Key

2. Variablen in Render eintragen

Einfache Methode - Alle auf einmal:

- o Klicke "Add from .env"
- o Füge folgenden kompletten Text ein:

- Wichtig: Ersetze sk-proj-xxxxxxxxxxxxxxx mit deinem echten OpenAI API Key
- o Wichtig: Ändere admin: meinpasswort 123 zu deinen gewünschten Login-Daten
- Wichtig: Ändere lightrag_secure_key_2024 zu deinem gewünschten API
 Key
- o Klicke "Add Variables"

3. Login nach Deployment

Nach erfolgreichem Deployment:

- URL: [Deine Render Service URL]
- Username: Was du bei AUTH ACCOUNTS vor dem ":" eingetragen hast
- Passwort: Was du bei AUTH ACCOUNTS nach dem ":" eingetragen hast

LightRAG Benutzeroberfläche

Hauptbereiche

Dokumentenbereich:

- Upload von Dokumenten
- Automatische Verarbeitung:
 - 1. Duplikate herausfiltern
 - 2. Text in Chunks aufteilen
 - 3. Vektoren erstellen und speichern
 - 4. Entitäten und Beziehungen extrahieren
 - 5. Konsolidierung bei 4+ Referenzen

Knowledge Graph:

- Visuelle Darstellung des Graphen
- Zoom- und Navigationsfunktionen
- Entitätseigenschaften anzeigen
- Beziehungen verfolgen

Retrieval-Tab:

- Testumgebung für Abfragen
- Verschiedene Modi verfügbar
- Kontext oder LLM-Antworten

Abfragemodi

- Naive: Einfache Textähnlichkeitssuche
- Local: Präzise Treffer im unmittelbaren Kontext
- Global: Semantische Suche im gesamten Graphen
- Hybrid: Kombination aus Vektor- und Graph-Suche
- Mix: Empfohlener Modus für beste Ergebnisse

N8N Integration

Workflow Import

Um die Übersichtlichkeit zu gewährleisten findest du den Workflow am Ende des Dokuments.

Workflow Import Anleitung:

- 1. Kopiere das komplette JSON oben
- 2. Gehe in n8n zu "Templates" → "Import from JSON"
- 3. Füge das JSON ein und klicke "Import"
- 4. Der Workflow wird automatisch erstellt

Nach dem Import konfigurieren:

1. OpenAI API Key hinzufügen:

- o Gehe zu "Credentials" in n8n
- o Füge deine OpenAI API Credentials hinzu
- o Verknüpfe sie mit dem "OpenAI Chat Model" Node

2. LightRAG API Key finden:

- o Gehe in deine LightRAG-Anwendung
- o Klicke auf den "API"-Tab
- o Klicke auf "Authorize"
- Unter "APIKey Header" gibst du deinen API Key an und wählst nochmal "Authorize"
- Das ist derselbe Key wie dein LIGHTRAG_API_KEY aus den Umgebungsvariablen

HTTP Request Node Konfiguration

1. cURL Import

- o Gehe in LightRAG zu API → Post Query
- o Klicke "Execute" um Schema zu laden
- o Kopiere den generierten cURL-Befehl
- o In n8n: HTTP Request Node → "Import cURL"

2. Authentifizierung Setup

- o Authentication: Generic Credential Type
- o Auth Type: Header Auth
- o Erstelle neues Credential
- o Name: X-API-Key
- o Value: [LightRAG API Key aus API-Tab]

3. Body Konfiguration

- o Body Type: JSON
- o Specify Body: Using Fields below
- o Header Parameter: query
- o Value: Automatisch aus vorherigem Node

Agent Integration

- Tool wird automatisch ausgelöst bei relevanten Fragen
- LightRAG generiert detaillierte Antworten mit Quellenangaben
- Nahtlose Integration in bestehende n8n-Workflows

Troubleshooting

Häufige Probleme

Deployment Fehler:

- Überprüfe Docker Image URL
- Stelle sicher, dass alle Umgebungsvariablen gesetzt sind
- Kontrolliere Disk-Mount-Path

API Verbindungsfehler:

- Validiere API Key
- Prüfe Service-URL
- Überprüfe Header-Authentifizierung in n8n

Schlechte Antwortqualität:

- Lade mehr relevante Dokumente hoch
- Teste verschiedene Abfragemodi
- Überprüfe Token-Limits für Entitäten

Performance Optimierung

Token Management:

- Setze maximale Token-Größen für Entitäten
- Begrenze Beziehungs-Token
- Überwache API-Verbrauch

Skalierung:

- Erhöhe Disk-Größe bei mehr Dokumenten
- Upgrade Render-Plan bei höherem Traffic
- Nutze Parallelitäts-Einstellungen

Nächste Schritte

- 1. Erste Dokumente hochladen und testen
- 2. N8N-Workflow an eigene Bedürfnisse anpassen
- 3. Monitoring und Optimierung einrichten

Der Workflow:

```
"name": "GraphRAG Agent Workflow",
  "nodes": [
      "parameters": {
        "options": {}
      "id": "51219c75-24d2-46de-bcdd-54c509cb8d67",
      "name": "When chat message received",
      "type": "@n8n/n8n-nodes-langchain.chatTrigger",
      "typeVersion": 1.1,
      "position": [
        320,
        120
      "webhookId": "graph-rag-chat"
    },
      "parameters": {
        "options": {
          "systemMessage": "=Du bist ein Graph RAG Experte. Nutze IMMER das
Graph Knowledge Expert Tool für deine Antworten.",
          "returnIntermediateSteps": true
```

```
}
      "id": "13519b5f-12b4-437f-97d4-f56d622530ae",
      "name": "AI Agent",
      "type": "@n8n/n8n-nodes-langchain.agent",
      "typeVersion": 1.7,
      "position": [
        540,
        120
      ]
    },
      "parameters": {
        "model": "gpt-4.1-nano",
        "options": {
          "frequencyPenalty": 0,
          "maxTokens": 4000,
          "responseFormat": "text",
          "presencePenalty": 0,
          "temperature": 0.1,
          "timeout": 60000,
          "maxRetries": 2,
          "topP": 0.9
        }
      },
      "id": "ce8ed2dd-e59d-4b2b-a277-7354180e4256",
      "name": "OpenAI Chat Model",
      "type": "@n8n/n8n-nodes-langchain.lmChatOpenAi",
      "typeVersion": 1.1,
      "position": [
        540,
        280
      ],
      "credentials": {
        "openAiApi": {
          "id": "DEINE-OPENAI-CREDENTIAL-ID",
          "name": "OpenAI Account"
      }
    },
      "parameters": {
        "sessionIdType": "customKey",
        "sessionKey": "={{ $('When chat message
received').item.json.sessionId }}",
        "contextWindowLength": 10
      "id": "661902a1-dbc7-4f5d-896a-1792795a119d",
      "name": "Window Buffer Memory",
      "type": "@n8n/n8n-nodes-langchain.memoryBufferWindow",
      "typeVersion": 1.2,
      "position": [
        540,
        360
      1
    },
      "parameters": {},
      "id": "386aa5bb-2804-4744-861f-e9d45c5a067c",
      "name": "Graph Knowledge Expert",
      "type": "@n8n/n8n-nodes-langchain.toolHttpRequest",
      "typeVersion": 1.2,
      "position": [
```

```
540,
             440
          1
       },
          "parameters": {
             "content": "## @ Graph RAG Agent Setup\n\n### Wichtige
Konfigurationsschritte:\n\n1. **LightRAG Service URL anpassen**\n
{\tt Ersetze `YOUR-LIGHTRAG-SERVICE` mit deiner tats\"{a}chlichen Service-URL \setminus n \setminus n2.}
**API Credentials erstellen**\n - Gehe zu Credentials \rightarrow Add Credential\n
- Wähle \"Header Auth\"\n - Name: `lightragApi`\n - Header Name: `X-
API-Key`\n - Header Value: Dein LightRAG API Key\n\n3. **OpenAI
Credentials**\n - Füge deine OpenAI API Credentials hinzu\n\n4.
**Workflow aktivieren**\n - Klicke auf \"Activate\" oben rechts\n\n###
Test:\nÖffne den Chat und stelle Fragen wie:\n- \"Welche Beziehungen
bestehen zwischen [Entität A] und [Entität B]?\"\n- \"Erkläre mir die
Zusammenhänge im Dokument X\"\n- \"Was sind die wichtigsten Konzepte und
wie hängen sie zusammen?\"",
              "height": 441.5293209876547,
              "width": 396.0802469135803,
             "color": 4
          "id": "91b8495b-6597-402c-be53-827a2cdcc860",
          "name": "Sticky Note",
          "type": "n8n-nodes-base.stickyNote",
          "typeVersion": 1,
          "position": [
             -260,
             120
          ]
       },
          "parameters": {
             "jsCode": "// Response Processing & Formatting\nconst response =
$input.item.json; \n\n// Extrahiere strukturierte Daten aus der LightRAG
Response\nlet processedResponse = {\n query: response.query || '',\n
answer: '', \n entities: [], \n relationships: [], \n sources: [], \n
confidence: 0,\n mode: response.mode || 'hybrid'\n};\n\n// Verarbeite die
Antwort\nif (response.response) {\n processedResponse.answer =
response.response; \n \n \n // Extrahiere Entitäten (falls vorhanden) \nif
(response.entities && Array.isArray(response.entities)) {\n
processedResponse.entities = response.entities.map(entity => ({\n
entity.name || entity.entity || '',\n type: entity.type || 'unknown',\n
description: entity.description || '', \n properties: entity.properties
|| {}\n }));\n}\n\n// Extrahiere Beziehungen (falls vorhanden)\nif
(response.relationships && Array.isArray(response.relationships)) {\n
processedResponse.relationships = response.relationships.map(rel => ({\n
source: rel.source || rel.from || '',\n target: rel.target || rel.to ||
               type: rel.relationship || rel.type || '',\n
                                                                                              strength:
rel.strength || rel.weight || 1,\n description: rel.description || ''\n
}));\n}\n\n// Extrahiere Quellen\nif (response.sources &&
Array.isArray(response.sources)) {\n processedResponse.sources =
response.sources.map(source => ({\n
                                                               document: source.document ||
source.file || '',\n page: source.page || null,\n relevance:
                                                                       excerpt: source.excerpt ||
source.relevance || source.score || 0,\n
source.text || ''\n }));\n}\n\n// Berechne Confidence Score\nif
(response.confidence) {\n processedResponse.confidence =
response.confidence;\n} else if (response.score) {\n
processedResponse.confidence = response.score;\n} else if
(processed Response.sources.length > 0) \ \{\n \ // \ Durchschnittliche \ Relevanz \ Anne \ 
als Confidence\n const avgRelevance =
processedResponse.sources.reduce((acc, s) => acc + s.relevance, 0) /
```

```
avgRelevance; \n \n \n // Formatiere die Antwort für bessere Lesbarkeit \nif
(processedResponse.entities.length > 0 ||
processedResponse.relationships.length > 0) {\n let formattedAnswer =
processedResponse.answer + '\\n\\n';\n \n if
(processedResponse.entities.length > 0) {\n formattedAnswer += 'II
**Identifizierte Entitäten:**\\n';\n
processedResponse.entities.forEach(entity => {\n
                                                     formattedAnswer += `•
${entity.name} (${entity.type})${entity.description ? ': ' +
entity.description : ''}\\n`;\n
                                 });\n
                                           formattedAnswer += '\\n';\n
\n \n if (processedResponse.relationships.length > 0) {\n
formattedAnswer += '\O **Gefundene Beziehungen:**\\n';\n
processedResponse.relationships.forEach(rel => {\n
                                                        formattedAnswer +=
`• {\text{rel.source}} \rightarrow {\text{rel.type}} \rightarrow {\text{rel.target}} \ ); \ )
formattedAnswer += '\bigsiz **Quellen:**\\n';\n
> 0) {\n}
processedResponse.sources.forEach((source, idx) => {\n
+= `${idx + 1}. ${source.document}${source.page ? ' (Seite ' + source.page
+ ')' : ''}\\n`;\n });\n }\n \n processedResponse.formattedAnswer = formattedAnswer;\n}\n\n/ Logging für Debugging\nconsole.log('Processed
Response:', JSON.stringify(processedResponse, null, 2));\n\nreturn
processedResponse;"
      "id": "7dc91ff3-4e51-4b01-a156-4d126716d1c7",
      "name": "Process Graph Response",
      "type": "n8n-nodes-base.code",
      "typeVersion": 2,
      "position": [
        1040,
        500
      "notesInFlow": false,
      "disabled": true
    },
      "parameters": {
        "content": "## 🔟 Optional: Response Processing\n\nDieser Code Node
kann aktiviert werden, um:\n- Graph-Daten zu strukturieren\n- Entitäten und
Beziehungen zu extrahieren\n- Antworten zu formatieren\n- Confidence Scores
zu berechnen\n\n**Aktivierung:**\n1. Rechtsklick auf den Node\n2.
\"Enable\" wählen\n3. Mit HTTP Request Tool verbinden",
        "height": 215.9999999999994,
        "color": 5
      "id": "3a463bfd-80c6-42c9-ad96-3d8f804ba5bf",
      "name": "Sticky Note1",
      "type": "n8n-nodes-base.stickyNote",
      "typeVersion": 1,
      "position": [
        1180,
        80
      ]
    },
      "parameters": {
        "httpMethod": "POST",
        "path": "graph-rag-webhook",
        "responseMode": "responseNode",
        "options": {
          "responseHeaders": {
            "entries": [
```

processedResponse.sources.length; \n processedResponse.confidence =

```
"name": "Access-Control-Allow-Origin",
              "value": "*"
          ]
        }
      }
    "id": "173448b8-e76a-47e9-95d7-8a14b8f6f961",
    "name": "Webhook (Alternative Trigger)",
    "type": "n8n-nodes-base.webhook",
    "typeVersion": 2,
    "position": [
      320,
      320
    "webhookId": "597de52e-d713-489b-9f0f-245237f26b9f",
    "disabled": true,
    "notes": "Alternative: Webhook für API Integration"
  },
    "parameters": {
      "respondWith": "allIncomingItems",
      "options": {}
    "id": "1bf886ec-128b-4862-93ee-f903a49cc0b6",
    "name": "Respond to Webhook",
    "type": "n8n-nodes-base.respondToWebhook",
    "typeVersion": 1.1,
    "position": [
     1260,
      620
    ],
    "disabled": true
  },
    "parameters": {},
    "type": "@n8n/n8n-nodes-langchain.memoryBufferWindow",
    "typeVersion": 1.3,
    "position": [
      600,
      640
    "id": "10254d87-20b3-407d-b684-e48036f932db",
    "name": "Simple Memory"
  },
    "parameters": {
      "options": {}
    "type": "n8n-nodes-base.httpRequestTool",
    "typeVersion": 4.2,
    "position": [
      680,
      340
    "id": "172c0bed-937a-4ed5-b640-8adc6fab25bb",
    "name": "HTTP Request"
  }
],
"pinData": {},
"connections": {
  "When chat message received": {
```

```
"main": [
      [
          "node": "AI Agent",
"type": "main",
          "index": 0
      ]
    ]
  "Webhook (Alternative Trigger)": {
    "main": [
      [
           "node": "AI Agent",
          "type": "main",
"index": 0
      ]
    1
  },
  "Process Graph Response": {
    "main": [
      [
          "node": "Respond to Webhook", "type": "main",
           "index": 0
        }
      ]
    ]
  "Simple Memory": {
    "ai_memory": [
      [
          "node": "AI Agent",
          "type": "ai memory",
          "index": 0
      ]
    ]
  "HTTP Request": {
    "ai_tool": [
      [
           "node": "AI Agent",
           "type": "ai tool",
           "index": 0
      1
    ]
 }
"active": false,
"settings": {
  "executionOrder": "v1"
"versionId": "WORKFLOW-VERSION-ID",
"meta": {
  "templateCredsSetupCompleted": true,
  "instanceId": "DEINE-N8N-INSTANCE-ID"
```

```
},
"id": "WORKFLOW-ID",
"tags": []
}
```